

자연어처리 기말 프로젝트 · 담당 파트 요약 (v2)

부동산 임대차 계약서 법률적 검토 AI

AI-Native Application Design — 계약서 특약사항 위험도 분류 & 법률 근거 기반 설명 시스템

v2: 모델 교체(RoBERTa) 및 데이터 정제/증강 실험 과정 반영

대체 대상 인간 역할 법률 상담사 / 계약서 1차 검토자

핵심 NLP 기술 문서 세그멘테이션 · 텍스트 분류(파인튜닝) · RAG(임베딩 검색) · LLM 기반 생성

작성일 2026년 7월

1 프로젝트 개요

기존 부동산 서비스에서 계약 진행 시 임차인이 접하는 계약서 특약사항은 형식이 다양하고 법률 지식 없이는 적절성을 판단하기 어렵다. 본 파트는 이 과정에서 “계약 조항의 적절성을 검토해주는 법률 상담사/1차 검토자” 역할을 AI로 대체하는 것을 목표로 한다.

전체 서비스는 두 파트로 구성된다. (1) 자연어 조건 입력 → 매물 추천 (팀원 파트, “공인중개사” 역할 대체) (2) 계약 확정 후 계약서 업로드 → 조항별 위험도 판별 및 설명 (본 파트, “법률 상담사” 역할 대체).

v1 대비 주요 변경사항

항목	v1	v2
분류 모델	klue/bert-base	klue/roberta-base
학습 데이터	296건 (수동 라벨링)	462건 (수동 296 + LLM 증강, 중복 제거 완료)
검증 정확도 / macro F1	0.850 / 0.845	0.968 / 0.965
신규 발견	-	RAG 유사도 스코어가 낮게 나오는 현상 확인 (원인 분석 및 개선 방향 도출)

2 데이터 증강 및 정제 실험 과정


분류기 성능을 높이기 위해 Gemini API로 학습 데이터를 대량 증강하는 과정에서, 실제 머신러닝 실무에서 흔히 발생하는 함정을 직접 겪고 해결한 과정을 기록한다.

- 1차 증강 시도** — Gemini에 라벨별 정의와 예시를 주고 700개 추가 생성을 요청. 실제로는 정상(0) 라벨만 270개가 반영되어 정상 370 / 주의 95 / 위험 101로 오히려 불균형이 심화됨.
- 이상 징후 포착** — 재학습 후 표준적인 조항("임차인은 임대인의 동의 없이 구조를 변경할 수 없다")이 78.1%의 확신으로 "주의"로 오분류됨. 학습 데이터의 최소 문장 길이(46자)보다 짧은 문장이어서 분포 밖(out-of-distribution) 입력에 취약한 것으로 진단.
- 전면 재증강** — 정상/주의/위험 각 300개씩, 문장 길이(20~45자 단문 30% + 장문 70%)를 라벨과 무관하게 분산시키도록 프롬프트를 재설계하여 요청.
- 경고** **가짜 성능 발견** — 재학습 결과 `eval_accuracy = 1.0`, `eval_f1_macro = 1.0`. 완벽한 검증 성능은 실무에서 데이터 누수(data leakage)의 강력한 신호로 간주하고 즉시 원인 조사.
- 원인 규명** — LLM이 대량 생성 시 동일한 문장을 반복하거나 한두 단어만 바꾼 근접 중복을 다수 생성함을 확인. 680행 중 완전 중복 108건, 앞부분 20자 기준 근접 중복이 포함된 행이 360건(전체의 절반 이상). 무작위 train/val 분할 시 이 중복 쌍이 양쪽에 나뉘어 들어가 모델이 "암기"로 100%를 낸 것으로 결론.
- 정제 및 재검증** — 완전 중복 제거(680→572) 및 문자열 유사도(SequenceMatcher ratio ≥ 0.82) 기반 근접 중복 제거(572→462) 수행 후 재학습. `eval_accuracy 0.968 / eval_f1_macro 0.965`로 현실적이고 신뢰 가능한 성능 확보.

교훈: LLM으로 학습 데이터를 대량 생성할 때는 반드시 중복/근접 중복 검사를 거친 뒤 train/val을 분할해야 한다. 검증 정확도가 비정상적으로 높게 나오면(특히 100%) 성능 향상이 아니라 데이터 누수를 의심하는 것이 올바른 반응이다.

3 최종 학습 데이터셋

`data/clauses.csv` — 정제 완료된 462건. 라벨 간 문장 길이 분포가 골고루 섞여 있어(15~178자) 문장 길이와 라벨 간 허위 상관관계 문제를 해소했다.



정제 과정에서 위험(2) 라벨의 중복 비율이 가장 높았던 관계로(원본 140건 중 78건만 고유), 현재 라벨 간 다소 불균형이 남아있다. 성능은 이미 목표치를 넘겼으나, 여유가 있다면 주의/위험 라벨을 반복 방지 지침을 강화한 프롬프트로 추가 보강할 수 있다.

4 전처리 — PDF 파싱 & 조항 세그멘테이션

`pdf_utils.py` 가 담당하며, 계약서 형식에 따라 두 갈래로 처리한다.

표준조항 분리

“제n조” 패턴을 기준으로 본문을 분리. 특약사항 헤더 이전까지만 대상으로 한다.

특약사항 분리

“특약사항” 헤더 탐지 후 번호 매김 항목 단위로 분리. 서명 블록 시작점 이전까지만 취급.

5 분류 모델 — 직접 파인튜닝

항목	내용
베이스 모델	klue/roberta-base (v1: klue/bert-base)
태스크	3-class 시퀀스 분류 (정상 / 주의 / 위험)
학습 데이터	data/clauses.csv (462건, 중복 제거 완료, 8:2 train/val split)
학습 설정	5 epoch, batch size 16, max length 128
최종 평가 결과	accuracy 0.968 / macro F1 0.965

성능 변화 추이

단계	데이터	accuracy	macro F1	비고
v1 (BERT)	296건 (원본)	0.850	0.845	정상 기준선
중간 (RoBERTa)	680건 (중복 다수 포함)	1.000	1.000	데이터 누수, 무효
v2 (RoBERTa)	462건 (중복 제거 완료)	0.968	0.965	신뢰 가능한 최종 성능

6 RAG — 법률 근거 검색

항목	내용
임베딩 모델	jhgan/ko-sroberta-multitask
지식베이스	data/law_articles.json — 법 조문 38건
검색 방식	코사인 유사도 top-k(기본 3) + 최소 유사도 임계값(0.25) 필터링

발견된 한계: 실제 조항-조문 매칭 시 유사도 점수가 대체로 0.5 내외로, 기대보다 낮게 형성됨을 확인했다. 원인 분석 결과, 법 조문(격식체·추상적 서술)과 계약서 특약 문장(구어체·구체적 서술) 간 문체 격차를 `ko-sroberta-multitask` (STS/NLI 기반 범용 문장유사도 모델)가 충분히 매꾸지 못하는 것으로 추정된다. 개선 방향으로 (1) query/passage를 구분해 학습된 검색 특화 임베딩 모델(예: KoE5, multilingual-e5)로 교체, (2) 법조문에 실제 계약서 문체의 예시 시나리오를 함께 임베딩하는 방식(document expansion)을 검토 중이다.

7 설명 생성 — Gemini API

항목	내용
모델	gemini-2.5-flash (google-genai SDK)
입력	조항 원문 + 분류 라벨 + RAG로 검색된 관련 법 조문
출력	3~5문장 설명 + 임차인이 취할 수 있는 행동 제안

프롬프트 설계 원칙: (1) 제공된 법 조문 범위 안에서만 근거 제시 (2) 근거 법률·조 명시 (3) 근거 부족 시 “단정하기 어렵다”고 답변. 계약서 내 개인정보(연락처·주민번호·이메일)는 API 전송 전 정규식으로 자동 마스킹한다.

8 출력 예시

실제 파이프라인 입출력 구조 예시이며, 설명 문구는 프롬프트 설계 의도를 보여주기 위한 대표 예시임.

```
{
  "clause": "임차인은 어떠한 사유로도 보증금 반환을 요구할 수 없다.",
  "source": "특약사항",
  "label": "위험",
  "confidence": 0.994,
  "references": [
    {"law": "주택임대차보호법", "title": "제10조 (강행규정)", "score": 0.71},
    {"law": "주택임대차보호법", "title": "제3조의2 (보증금의 회수)", "score": 0.63}
  ],
  "explanation": "이 조항은 주택임대차보호법 제10조에 따라 임차인에게 불리한  
강행규정 위반 약정으로 효력이 없습니다. 보증금 반환청구권은 법으로  
보장된 권리로, 특약으로 사전에 포기시킬 수 없습니다."
}
```

9 한계 및 향후 과제

구분	내용
입력 범위	텍스트 추출 가능한 전자계약 PDF 전제, 스캔본/이미지 PDF는 별도 OCR 필요
법적 효력	참고용 도구이며 법적 효력을 갖는 자문을 대체하지 않음
데이터 균형	정제 후 주의(112)/위험(78) 라벨이 정상(272) 대비 다소 부족, 추가 보강 여지 있음
RAG 검색 품질	임베딩 모델을 검색 특화 모델로 교체하는 개선 작업 진행 예정
확장 가능성	설명 생성 단계를 자체 LoRA 파인튜닝 모델로 대체해 외부 API 의존도 축소 검토 중