

자연어처리 기말 프로젝트 · 담당 파트 요약 (v3)

부동산 임대차 계약서 법률적 검토 AI

AI-Native Application Design — 계약서 특약사항 위험도 분류 & 법률 근거 기반 설명 시스템

v3: 데이터 762건 균형화 완료, 최종 검증 accuracy·F1 0.980

대체 대상 인간 역할 법률 상담사 / 계약서 1차 검토자

핵심 NLP 기술 문서 세그멘테이션 · 텍스트 분류(파인튜닝) · RAG(임베딩 검색) · LLM 기반 생성

작성일 2026년 7월

1 프로젝트 개요

기존 부동산 서비스에서 계약 진행 시 임차인이 접하는 계약서 특약사항은 형식이 다양하고 법률 지식 없이는 적절성을 판단하기 어렵다. 본 파트는 이 과정에서 “계약 조항의 적절성을 검토해주는 법률 상담사/1차 검토자” 역할을 AI로 대체하는 것을 목표로 한다.

전체 서비스는 두 파트로 구성된다. (1) 자연어 조건 입력 → 매물 추천 (팀원 파트, “공인중개사” 역할 대체) (2) 계약 확정 후 계약서 업로드 → 조항별 위험도 판별 및 설명 (본 파트, “법률 상담사” 역할 대체).

버전별 변화 요약

항목	v1	v2	v3 (최종)
분류 모델	klue/bert-base	klue/roberta-base	klue/roberta-base
학습 데이터	296건	462건 (중복 제거)	762건 (중복 제거 + 균형화)
라벨 비율(정상:주의:위험)	100:95:101	272:112:78	272:247:243 (최대/최소 1.12배)
검증 accuracy / macro F1	0.850 / 0.845	0.968 / 0.965	0.980 / 0.980

2 데이터 증강 및 정제 실험 과정


분류기 성능을 높이기 위해 Gemini API로 학습 데이터를 대량 증강하는 과정에서, 실제 머신러닝 실무에서 흔히 발생하는 함정을 직접 겪고 해결한 과정을 기록한다.

- 1 **1차 증강 시도** — 700개 추가 요청, 실제로는 정상(0)만 270개 반영되어 불균형 심화 (370:95:101).
- 2 **이상 징후 포착** — 표준 조항이 78.1% 확신으로 오분류. 학습 데이터 최소 길이(46자)보다 짧은 분포 밖(out-of-distribution) 입력에 취약함을 진단.
- 3 **전면 재증강 및 길이 다양화** — 정상/주의/위험 각 300개, 짧은 문장(20~45자) 30% 포함하도록 재설계.
- 4 **경고** **가짜 성능 발견** — `eval_accuracy = 1.0`. 완벽한 검증 성능을 데이터 누수 신호로 간주하고 즉시 원인 조사.
- 5 **원인 규명** — LLM 대량 생성 시 근접 중복 문장이 다량 발생함을 확인 (680행 중 완전중복 108건, 근접중복 포함 360행). 무작위 분할 시 중복 쌍이 train/val에 나뉘어 들어가 “암기”로 100%를 낸 것으로 결론.
- 6 **1차 정제** — 완전/근접 중복 제거(680→462) 후 재학습. `accuracy 0.968 / F1 0.965`로 현실적 성능 확보. 단, 정제 과정에서 주의(112)·위험(78) 라벨이 상대적으로 줄어 불균형 재발.
- 7 **중복 방지 프롬프트 재설계** — 소재당 1개 제한, 이전 생성분과 60% 이상 유사 금지, 50개씩 소량 배치 요청 방식으로 프롬프트를 개선하여 주의·위험 라벨을 단계적으로 보강.
- 8 **최종** **2차 정제 및 균형화** — 누적 962행에서 완전중복(157건)·근접중복 제거 후 **762행, 272:247:243 (최대/최소 1.12배)**로 균형 달성. 재학습 결과 **accuracy 0.980 / macro F1 0.980**. 5 에폭에 걸쳐 88%→95%→95%→97%→98%로 점진적으로 수렴하여 데이터 누수 없이 안정적으로 개선됐음을 확인.

결론: 소량 배치 요청 + 명시적 중복 방지 지침 + 사후 중복 검사(완전/근접)의 3중 안전장치를 거쳐, 데이터 양(296→762건, 2.6배)과 균형(최대/최소 3.5배→1.12배)을 동시에 개선했고, 검증 성능도 0.845→0.980으로 유의미하게 향상됐다. 100%라는 비정상 수치를 그대로 보고하지 않고 원인을 규명해 재현 가능한 개선으로 전환한 과정 자체가 본 프로젝트의 방법론적 신뢰성을 보여준다.

3 최종 학습 데이터셋

`data/clauses.csv` — 정제·균형화 완료된 762건. 라벨 간 문장 길이 분포도 모든 라벨에 걸쳐 15~178자로 고르게 섞여 있어, 길이-라벨 간 허위 상관관계 문제가 해소됐다.



최대/최소 라벨 비율 1.12배로 사실상 균형 데이터셋. v1(100:95:101, 자연 균형) → v2(272:112:78, 정제 과정에서 재불균형) → v3(272:247:243, 목표 재보강으로 균형 회복)의 과정을 거쳤다.

4 전처리 — PDF 파싱 & 조항 세그멘테이션

`pdf_utils.py` 가 담당하며, 계약서 형식에 따라 두 갈래로 처리한다.

표준조항 분리

“제n조” 패턴을 기준으로 본문을 분리. 특약사항 헤더 이전까지만 대상으로 한다.

특약사항 분리

“특약사항” 헤더 탐지 후 번호 매김 항목 단위로 분리. 서명 블록 시작점 이전까지만 취급.


5 분류 모델 — 직접 파인튜닝

항목	내용
베이스 모델	klue/roberta-base
태스크	3-class 시퀀스 분류 (정상 / 주의 / 위험)
학습 데이터	data/clauses.csv (762건, 중복 제거 + 균형화 완료, 8:2 train/val split)
학습 설정	5 epoch, batch size 16, max length 128
최종 평가 결과	accuracy 0.980 / macro F1 0.980

성능 변화 추이 (전 과정)

단계	데이터	accuracy	macro F1	비고
v1 (BERT)	296건 (원본)	0.850	0.845	기준선
중간 (RoBERTa)	680건 (중복 다수)	1.000	1.000	데이터 누수, 무효
v2 (RoBERTa)	462건 (1차 정제)	0.968	0.965	불균형 재발(272:112:78)
v3 (RoBERTa)	762건 (2차 정제+균형화)	0.980	0.980	최종, 신뢰 가능

학습 곡선 (v3, 에폭별 검증 성능)



점진적 수렴 곡선(급격한 100% 도달 없음)은 이번 학습이 데이터 누수 없이 정상적으로 이루어졌음을 뒷받침하는 근거다.

6 RAG — 법률 근거 검색

항목	내용
임베딩 모델	jhgan/ko-sroberta-multitask
지식베이스	data/law_articles.json — 법 조문 38건
검색 방식	코사인 유사도 top-k(기본 3) + 최소 유사도 임계값(0.25) 필터링

진행 중인 개선 과제: 조항-조문 매칭 시 유사도 점수가 0.5 내외로 낮게 형성되는 현상을 확인했다. 원인은 지식베이스의 양이 아니라, 법 조문(격식체)과 계약서 문장(구어체) 간 문체 격차를 현재 임베딩 모델(STS/NLI 기반 범용 모델)이 충분히 메꾸지 못하기 때문으로 분석된다. Query/passage를 구분해 학습된 검색 특화 모델(KoE5, multilingual-e5 등)로 교체하는 작업을 다음 단계로 진행할 예정이다.

7 설명 생성 — Gemini API

항목	내용
모델	gemini-2.5-flash (google-genai SDK)
입력	조항 원문 + 분류 라벨 + RAG로 검색된 관련 법 조문
출력	3~5문장 설명 + 임차인이 취할 수 있는 행동 제안

프롬프트 설계 원칙: (1) 제공된 법 조문 범위 안에서만 근거 제시 (2) 근거 법률·조 명시 (3) 근거 부족 시 “단정하기 어렵다”고 답변. 계약서 내 개인정보는 API 전송 전 정규식으로 자동 마스킹.

8 출력 예시

실제 파이프라인 입출력 구조 예시이며, 설명 문구는 프롬프트 설계 의도를 보여주기 위한 대표 예시임.

```
{
  "clause": "임차인은 어떠한 사유로도 보증금 반환을 요구할 수 없다.",
  "source": "특약사항",
  "label": "위험",
  "confidence": 0.994,
  "references": [
    {"law": "주택임대차보호법", "title": "제10조 (강행규정)", "score": 0.71},
    {"law": "주택임대차보호법", "title": "제3조의2 (보증금의 회수)", "score": 0.63}
  ],
  "explanation": "이 조항은 주택임대차보호법 제10조에 따라 임차인에게 불리한  
강행규정 위반 약정으로 효력이 없습니다. 보증금 반환청구권은 법으로  
보장된 권리로, 특약으로 사전에 포기시킬 수 없습니다."
}
```

9 한계 및 향후 과제

구분	내용
입력 범위	텍스트 추출 가능한 전자계약 PDF 전제, 스캔본/이미지 PDF는 별도 OCR 필요
법적 효력	참고용 도구이며 법적 효력을 갖는 자문을 대체하지 않음
RAG 검색 품질	임베딩 모델을 검색 특화 모델(KoE5 등)로 교체하는 작업 진행 예정
확장 가능성	설명 생성 단계를 자체 LoRA 파인튜닝 모델로 대체해 외부 API 의존도 축소 검토 중