

자연어처리 기말 프로젝트 · 담당 파트 요약 (v4)

부동산 임대차 계약서 법률적 검토 AI

AI-Native Application Design — 계약서 특약사항 위험도 분류 & 법률 근거 기반 설명 시스템

v4: RAG 임베딩 모델 교체(KoE5) + 임계값 튜닝 + 실제계약서 파이프라인 검증 완료

대체 대상 인간 역할 법률 상담사 / 계약서 1차 검토자

핵심 NLP 기술 문서 세그멘테이션 · 텍스트 분류(파인튜닝) · RAG(검색 특화 임베딩) · LLM 기반 생성

작성일 2026년 7월

1 프로젝트 개요

기존 부동산 서비스에서 계약 진행 시 임차인이 접하는 계약서 특약사항은 형식이 다양하고 법률 지식 없이는 적절성을 판단하기 어렵다. 본 파트는 이 과정에서 “계약 조항의 적절성을 검토해주는 법률 상담사/1차 검토자” 역할을 AI로 대체하는 것을 목표로 한다.

전체 서비스는 두 파트로 구성된다. (1) 자연어 조건 입력 → 매물 추천 (팀원 파트, “공인중개사” 역할 대체) (2) 계약 확정 후 계약서 업로드 → 조항별 위험도 판별 및 설명 (본 파트, “법률 상담사” 역할 대체).

버전별 변화 요약

항목	v2	v3	v4 (최종)
분류기	klue/roberta-base, 462건	klue/roberta-base, 762건(균형화)	동일 (변경 없음)
분류 성능	0.968 / 0.965	0.980 / 0.980	0.980 / 0.980
RAG 임베딩 모델	ko-sroberta-multitask	ko-sroberta-multitask (미해결로 명시)	nlpai-lab/KoE5로 교체
RAG 유사도(관련 조문)	~0.5 내외	~0.5 내외	0.68~0.70대로 상승
근거 필터 임계값	0.25	0.25	0.45 (실계약서 테스트로 튜닝)
검증 방식	학습 데이터 지표만	학습 데이터 지표만	샘플 계약서 9개 조항 실제 파이프라인 실행 검증

2 분류기 데이터 증강 및 정제 (v3까지의 과정 요약)

분류기 성능을 높이기 위해 Gemini API로 학습 데이터를 대량 증강하는 과정에서, 실제 머신러닝 실무에서 흔히 발생하는 함정을 직접 겪고 해결했다. (상세 과정은 이전 버전 리포트 참고, 본 리포트는 결과만 요약)

- 1 **1차 증강 시도** — 정상(0) 위주로 늘어나 불균형 심화 (370:95:101).
- 2 **이상 징후 포착 → 원인 규명** — 표준 조항 오분류(짧은 문장 OOD) 및 완벽한 검증 성능(eval=1.0)이 데이터 누수(근접 중복 문장 다수) 때문임을 규명.
- 3 **1차 정제** — 중복 제거(680→462) 후 재학습, accuracy 0.968 / F1 0.965. 단 라벨 재불균형(272:112:78).
- 4 **최종 중복 방지 프롬프트 재설계 + 2차 정제·균형화** — 소재당 1개 제한, 50개씩 소량 배치 요청으로 재증강 후 근접중복 제거하여 762건, 272:247:243(최대/최소 1.12배) 균형 달성. 재학습 결과 **accuracy 0.980 / macro F1 0.980**. 5 에폭에 걸쳐 88%→95%→95%→97%→98%로 점진 수렴하여 데이터 누수 없이 안정적으로 개선됐음을 확인.

3 RAG 임베딩 모델 교체 & 임계값 튜닝

문제 진단

기존 `jhgan/ko-sroberta-multitask` 는 STS/NLI(두 문장이 같은 의미인지 판별)용으로 학습된 범용 문장 임베딩 모델이다. 계약서 조항(짧고 구어체)과 법 조문(길고 격식체) 사이의 문체 격차를 이 모델이 충분히 메우지 못해, 실제로 관련 있는 조문끼리도 유사도가 0.5 안팎으로 낮게 나오는 문제가 있었다.

해결: 검색 특화 모델(KoE5)로 교체

항목	이전	이후
임베딩 모델	<code>jhgan/ko-sroberta-multitask</code>	<code>nlpai-lab/KoE5</code>
학습 목적	문장 간 유사도(STS/NLI), 대칭적	검색(query→passage), 비대칭적
인코딩 방식	원문 그대로 인코딩	질의를 " <code>query: </code> ", 문서는 " <code>passage: </code> " 접두사 부여 (E5 컨벤션)
관련 조문 유사도(실측)	~0.5 내외	0.68~0.70 (보증금 반환 사례)

재임베딩 검증: `rag/rebuild_embeddings.py` 로 법 조문 38건을 KoE5로 재인코딩한 뒤 샘플 질의 3건으로 확인한 결과, “보증금 반환 요구 불가” 조항이 관련 조문(제3조의2·제3조의3 등)과 0.68~0.70의 유사도로 명확히 매칭됨을 확인했다 (교체 전 대비 상승 확인).

임계값(min_score) 재튜닝 — 실계약서 테스트 기반

모델 교체 후 baseline 유사도 자체가 높아지면서, 기존 임계값(0.25)은 무관한 조문까지 통과시키는 문제가 드러났다(예: “반려동물 금지” 조항에 무관한 신탁법 조문이 0.45~0.48로 걸림). 실제 샘플 계약서로 반복 테스트하여 아래와 같이 임계값을 조정했다.

테스트 케이스	매칭	유사도	판단
보증금 반환 거부 (위험)	제3조의2 등 3건	0.68~0.70	명확히 유지되어야 함
무단 잠금장치 변경 (주의)	형법 제319조(주거침입)	0.509	진짜 근거 — 반드시 살려야 함
반려동물 특수청소 비(주의)	민법 제623조 등	0.38~0.41	해당 소재를 다루는 조문이 없어 생긴 약한 매칭 — 걸려야 함

0.509(진짜 근거)와 0.41 이하(노이즈) 사이에서 경계를 잡아 **min_score = 0.25 → 0.45**로 조정했다. 이 값은 “근거가 없으면 단정하지 말라”는 explainer의 프롬프트 원칙과도 맞물려, 애매한 조항에서는 근거 목록이 비게 되어 LLM이 “특정 법률로 직접 금지되진 않지만”처럼 더 정직하게 답하도록 유도한다.

주의: 이 임계값은 실계약서 1건(9개 조항)에서 관찰된 소수 사례로 조정한 것이라, 더 다양한 계약서로 검증이 누적되면 재조정이 필요할 수 있다(9절 한계 참고).

4 실제 파이프라인 실행 검증

sample_contract.pdf (표준조항 4개 + 특약사항 5개, 총 9개 조항)를 전체 파이프라인에 직접 통과시켜 검증했다. **정상 6 / 주의 2 / 위험 1**로 분류되었으며, 위험·주의 조항 3건에 대해서만 RAG 검색과 Gemini 설명 생성이 실행됐다 (정상 조항은 API 호출 자체를 생략).

위험 임차인은 어떠한 사유로도 보증금 반환을 요구할 수 없다.

근거: 제3조의2(보증금의 회수) 0.6976 · 제3조의3(임차권등기명령) 0.6956 · 제3조의2 제7항(반환채무 승계) 0.6827

설명 요지: 임차권등기명령·보증금 반환채무 승계 규정을 근거로, 사전 포기 약정은 무효라고 명확히 지적. 계약 전 조항 삭제를 강력 권고.

주의 월 차임이 1일이라도 지체되면 임대인이 사전 통지 없이 출입문을 잠글 수 있다.

근거: 형법 제319조(주거침입) 0.5092 · 제6조의2(목시적 갱신 해지) 0.4861

설명 요지: 임대인의 무단 출입/잠금장치 변경은 주거침입죄에 해당할 수 있음을 정확히 지적, 조항 삭제 요청 권고.

주의 반려동물을 기를 경우 퇴거 시 특수청소비 100만원을 무조건 지급한다.

근거: 없음 (임계값 0.45 미만으로 모두 필터링됨)

설명 요지: “특정 법률 조항으로 직접 금지되는 것은 아니지만, 실손해와 무관한 일률적 과다 청구는 분쟁 소지가 있다”고 솔직하게 답변 — 근거 없이 특정 조문을 억지로 인용하지 않음.

나머지 표준조항 4건과 특약사항 2건은 모두 정상으로 분류되어 별도 설명 생성 없이 통과됨.

5 왜 이 아키텍처가 단순 LLM API 호출보다 나은가


가장 단순한 대안은 계약서 전문을 그대로 프롬프트에 넣고 “위험 조항을 찾아 설명해줘”라고 LLM에 한 번에 요청하는 방식이다. 본 프로젝트는 (1) 세그멘테이션 (2) 파인튜닝 분류기 (3) RAG 검색 (4) LLM 설명 생성을 분리된 단계로 설계했다. 아래는 그 근거다.

구분	단순 LLM API 한 번 호출	본 파이프라인 (분류기+RAG+LLM)
법적 근거 정확성	모델이 내부 지식만으로 법 조문을 인용 → 조문 번호·내용을 그럴듯하게 지어내는 환각(hallucination) 위험	RAG가 실제 <code>law_articles.json</code> 에서 검색한 조문만 프롬프트에 주입 → LLM은 주어진 근거 범위 안에서만 인용 가능
판단 일관성	같은 조항도 프롬프트/온도(temperature)에 따라 위험도 판단이 매번 달라질 수 있음	분류기는 고정된 가중치로 결정적·가깝게 판단 (동일 입력 → 동일 라벨), 762건 검증 데이터로 정확도(0.980) 수치화 가능
비용·속도	계약서의 모든 조항(9개)마다 매번 LLM 호출	분류는 코걸 소형 모델(무료·고속)이 전담하고, 위험·주의로 판정된 조항 (본 테스트에서 3/9, 33%)에 대해서만 LLM API 호출 → 호출량 최소화
검증 가능성	출력 결과만 있고 왜 그렇게 판단했는지 근거가 불투명(블랙박스)	라벨 확신도(confidence), 근거 조문, 유사도 점수가 모두 함께 출력되어 사람이 결과를 직접 검증할 수 있음
법 개정 대응	법이 바뀌면 프롬프트를 다시 손보거나 모델의 내부 지식 업데이트를 기다려야 함	<code>law_articles.json</code> 만 갱신하면 즉시 반영, 분류 모델 재학습 불필요
개인정보 노출	계약서 전문(임대인·임차인 정보 포함 가능)을 매번 외부 API로 전송	정상 조항은 API로 전송조차 되지 않고, 위험·주의 조항만 마스킹 후 전송되어 노출 범위 최소화
도메인 특화	범용 모델은 한국 주택임대차법의 세부 뉘앙스(강행 규정 vs 임의규정 등)를 놓칠 수 있음	분류기를 한국 임대차 특약사항 데이터로 직접 파인튜닝하여 도메인에 맞게 최적화, 성능을 762건 데이터로 실측

핵심 요지: LLM은 “그럴듯한 문장을 생성하는 데” 강하지만 “이 조항이 왜 위험한지에 대한 정확한 법적 근거를 아는 데”는 근본적으로 취약하다(파라미터에 저장된 지식은 오래되거나 부정확할 수 있고, 확인되지 않은 사실도 확신 있게 말할 수 있다). 본 아키텍처는 “판단(분류)”과 “근거 조회(RAG)”를 LLM 바깥에서 검증 가능한 형태로 처리하고, LLM은 마지막 단계인 “근거를 사람이 이해하기 쉬운 문장으로 풀어 설명하는 역할”에만 국한시킨다. 실제로 2절의 “반려동물 청소비” 사례에서, 근거가 없을 때 LLM이 억지로 조문을 갖다 붙이지 않고 “직접적으로 금지되진 않지만”이라고 정직하게 답한 것이 이 설계의 효과를 보여준다.

6 분류기 최종 학습 데이터셋

data/clauses.csv — 정제+균형화 완료된 762건.



최대/최소 라벨 비율 1.12배로 사실상 균형 데이터셋.

분류 성능

단계	데이터	accuracy	macro F1	비고
v1 (BERT)	296건 (원본)	0.850	0.845	기준선
중간 (RoBERTa)	680건 (중복 다수)	1.000	1.000	데이터 누수, 무효
v3 (RoBERTa)	462건 (1차 정제)	0.968	0.965	불균형 재발(272:112:78)
v4 (RoBERTa)	762건 (2차 정제+균형화)	0.980	0.980	최종, 실제약서 검증까지 완료

7 전처리 — PDF 파싱 & 조항 세그멘테이션

`pdf_utils.py` 가 담당하며, 계약서 형식에 따라 두 갈래로 처리한다.

표준조항 분리

“제n조” 패턴을 기준으로 본문을 분리. 특약사항 헤더 이전까지만 대상으로 한다.

특약사항 분리

“특약사항” 헤더 탐지 후 번호 매김 항목 단위로 분리. 서명 블록 시작점 이전까지만 취급.

8 설명 생성 — Gemini API

항목	내용
모델	gemini-2.5-flash (google-genai SDK)
입력	조항 원문 + 분류 라벨 + RAG로 검색된 관련 법 조문(있는 경우만)
출력	3~5문장 설명 + 임차인이 취할 수 있는 행동 제안

프롬프트 설계 원칙: (1) 제공된 법 조문 범위 안에서만 근거 제시 (2) 근거 법률·조 명시 (3) 근거 부족 시 “단정하기 어렵다”고 답변. 계약서 내 개인정보는 API 전송 전 정규식으로 자동 마스킹.

9 한계 및 향후 과제

구분	내용
RAG 커버리지	반려동물 특수청소비처럼 특정 법 조문이 존재하지 않는 소재는 근거 없이 “주의” 판단에만 의존 — 약관의 규제에 관한 법률 등 일반 조항과의 매칭 정교화 여지
임계값(0.45) 검증 규모	실계약서 1건(9개 조항)의 소수 사례로 튜닝된 값이라, 더 많은 계약서 샘플로 검증이 누적되어야 함
LLM 설명 생성 자체의 한계	RAG로 근거를 제한해도 Gemini의 문장 생성 과정에서 미세한 과장·왜곡 가능성은 완전히 배제되지 않음 (사람의 최종 확인 필요)
입력 범위	텍스트 추출 가능한 전자계약 PDF 전제, 스캔본/이미지 PDF는 별도 OCR 필요
법적 효력	참고용 도구이며 법적 효력을 갖는 자문을 대체하지 않음
확장 가능성	설명 생성 단계를 자체 LoRA 파인튜닝 모델로 대체해 외부 API 의존도 축소 검토 중