

자연어처리 기말 프로젝트 · 담당 파트 최종 요약

부동산 임대차 계약서 법률적 검토 AI

AI-Native Application Design — 계약서 특약사항 위험도 분류 & 법률 근거 기반 설명 시스템

v5 · 최종본

대체 대상 인간 역할 법률 상담사 / 계약서 1차 검토자

핵심 NLP 기술 문서 세그멘테이션 · 텍스트 분류(파인튜닝) · RAG(검색 특화 임베딩) · LLM 기반 생성

최종 상태 분류기 762건/accuracy · F1 0.980 · RAG 지식베이스 45건(KoE5, min_score 0.45) · 실계약서 파이프라인 검증 완료

작성일 2026년 7월

1 프로젝트 개요

기존 부동산 서비스에서 계약 진행 시 임차인이 접하는 계약서 특약사항은 형식이 다양하고 법률 지식 없이는 적절성을 판단하기 어렵다. 본 파트는 이 과정에서 “계약 조항의 적절성을 검토해주는 법률 상담사/1차 검토자” 역할을 AI로 대체하는 것을 목표로 한다.


전체 서비스는 두 파트로 구성된다. (1) 자연어 조건 입력 → 매물 추천 (팀원 파트, “공인중개사” 역할 대체) (2) 계약 확정 후 계약서 업로드 → 조항별 위험도 판별 및 설명 (본 파트, “법률 상담사” 역할 대체).

최종 시스템 상태 요약

구성 요소	최종 상태
조항 분류기	klue/roberta-base 파인튜닝, 학습데이터 762건(정상 272/주의 247/위험 243, 중복 제거·균형화), accuracy 0.980 / macro F1 0.980
RAG 임베딩 모델	nlpai-lab/KoE5 (검색 특화, query/passage 비대칭 인코딩)
RAG 법률 지식베이스	data/law_articles.json, 45건 (주택임대차보호법·민법·형법·공동주택관리법 등)
RAG 근거 필터 임계값	min_score = 0.45 (실계약서 테스트로 튜닝)
설명 생성	Gemini 2.5 Flash, 근거 조문 범위 내에서만 인용하도록 프롬프트 제약 + PII 마스킹
검증	학습 데이터 지표(0.980/0.980) + 실계약서(sample_contract.pdf) 9개 조항 파이프라인 실행 검증 + 지식베이스 확장분 8개 질의 유사도 검증

2 시스템 아키텍처

계약서 PDF 업로드부터 최종 설명 출력까지 4단계로 분리된 파이프라인으로 설계했다. 각 단계는 독립적으로 교체·검증 가능하다.



정상으로 분류된 조항은 RAG 검색과 LLM 호출을 생략해 API 사용량을 최소화한다 (9절 “왜 이 아키텍처가 유리한가” 참고). 법이 개정되면 law_articles.json만 갱신하면 되고 분류기 재학습은 필요 없다.

3 분류기 데이터 증강 및 정제 과정

분류기 성능을 높이기 위해 Gemini API로 학습 데이터를 대량 증강하는 과정에서, 실제 머신러닝 실무에서 흔히 발생하는 함정(데이터 누수, 길이 편향, 라벨 불균형)을 직접 겪고 진단하여 해결했다.

- 1 **1차 증강 시도** — 700개 추가 요청, 실제로는 정상(0) 위주로 반영되어 불균형 심화 (370:95:101).
- 2 **이상 징후 포착** — 표준 조항이 78.1% 확신으로 오분류됨을 발견. 학습 데이터 최소 길이(46자)보다 짧은 분포 밖(out-of-distribution) 입력에 취약함을 진단.
- 3 **전면 재증강 및 길이 다양화** — 정상/주의/위험 각 300개, 짧은 문장(20~45자) 30% 포함하도록 재설계.
- 4 **경고 가짜 성능 발견** — `eval_accuracy = 1.0`. 완벽한 검증 성능을 데이터 누수 신호로 간주하고 즉시 원인 조사.
- 5 **원인 규명** — LLM 대량 생성 시 근접 중복 문장이 다량 발생함을 확인 (680행 중 완전중복 108건, 근접중복 포함 360행). 무작위 분할 시 중복 쌍이 train/val에 나뉘어 들어가 “암기”로 100%를 낸 것으로 결론.
- 6 **1차 정제** — 완전/근접 중복 제거(680→462) 후 재학습. `accuracy 0.968 / F1 0.965`로 현실적 성능 확보. 단, 정제 과정에서 주의(112)·위험(78) 라벨이 상대적으로 줄어 불균형 재발.
- 7 **중복 방지 프롬프트 재설계** — 소제당 1개 제한, 이전 생성분과 60% 이상 유사 금지, 50개씩 소량 배치 요청 방식으로 프롬프트를 개선하여 주의·위험 라벨을 단계적으로 보강.
- 8 **최종 2차 정제 및 균형화** — 누적 962행에서 완전중복·근접중복 제거 후 **762행, 272:247:243(최대/최소 1.12배)**로 균형 달성.


결론: 소량 배치 요청 + 명시적 중복 방지 지침 + 사후 중복 검사(완전/근접)의 3중 안전장치를 거쳐, 데이터 양(296→762건, 2.6배)과 균형(최대/최소 3.5배→1.12배)을 동시에 개선했다. 100%라는 비정상 수치를 그대로 보고하지 않고 원인을 규명해 재현 가능한 개선으로 전환한 과정 자체가 본 프로젝트의 방법론적 신뢰성을 보여준다.

4 분류기 최종 성능

항목	내용
베이스 모델	klue/roberta-base
태스크	3-class 시퀀스 분류 (정상=0 / 주의=1 / 위험=2)
학습 데이터	data/clauses.csv (762건, 8:2 train/val split, stratify)
학습 설정	5 epoch, batch size 16, max length 128, metric_for_best_model=f1_macro
최종 평가 결과	accuracy 0.980 / macro F1 0.980


성능 변화 추이 (전 과정)

단계	데이터	accuracy	macro F1	비고
v1 (BERT)	296건 (원본)	0.850	0.845	기준선
중간 (RoBERTa)	680건 (중복 다수)	1.000	1.000	데이터 누수, 무효
1차 정제 (RoBERTa)	462건	0.968	0.965	불균형 재발(272:112:78)
최종 (RoBERTa)	762건 (2차 정제+균형화)	0.980	0.980	최종, 실계약서 검증 완료



최종 데이터셋 라벨 분포 (최대/최소 비율 1.12배, 사실상 균형).

학습 곡선 (에폭별 검증 성능)



점진적 수렴 곡선(급격한 100% 도달 없음)은 이번 학습이 데이터 누수 없이 정상적으로 이루어졌음을 뒷받침하는 근거다.

5 RAG (1) 임베딩 모델 교체 — ko-sroberta → KoE5

문제 진단

초기 임베딩 모델 `jhgan/ko-sroberta-multitask` 는 STS/NLI(두 문장이 같은 의미인지 판별)용으로 학습된 범용 문장 임베딩 모델이다. 계약서 조항(짧고 구어체)과 법 조문(길고 격식체) 사이의 문체 격차를 이 모델이 충분히 메우지 못해, 실제로 관련 있는 조문끼리도 유사도가 0.5 안팎으로 낮게 나오는 문제가 있었다.

해결: 검색 특화 모델(KoE5)로 교체

항목	이전	이후
임베딩 모델	<code>jhgan/ko-sroberta-multitask</code>	<code>nlpai-lab/KoE5</code>
학습 목적	문장 간 유사도(STS/NLI), 대칭적	검색(query→passage), 비대칭적
인코딩 방식	원문 그대로 인코딩	질의를 " <code>query: </code> ", 문서는 " <code>passage: </code> " 접두사 부여 (E5 컨벤션)
관련 조문 유사도(실측, 보증금 반환 사례)	~0.5 내외	0.68~0.70

검증 `rag/rebuild_embeddings.py` 로 법 조문을 KoE5로 재인코딩한 뒤 실제계약서 조항 기반 질의로 확인한 결과, 관련 조문 유사도가 확실히 상승했음을 확인했다 (아래 8절 표에 전체 검증 결과 정리).

6 RAG (2) 법률 지식베이스 확장 — 38건 → 45건

`min_score` 튜닝 과정에서, 분류기 학습 데이터의 소재 다양성 목록(보증금·갱신·원상복구·관리비·소음 등 14개 항목)과 기존 법 조문 38건을 대조했다. 그 결과 **관리비, 층간소음, 설비 하자·수선비 전가, 임차인 사망 시 승계, 연체 해지 요건**처럼 실제로 관련 법이 존재하는데도 지식베이스에 빠져 있는 소재가 확인됐다. 이 공백만 메우기 위해 아래 7건을 기존과 동일한 스타일(조문 요지 + 특약 상황 해석)로 추가했다.

추가 조문	대응하는 특약 상황
민법 제626조 (임차인의 상환청구권)	수선비·관리비를 이유 불문 임차인에게 전가하고 상환청구권을 배제하는 특약
민법 제627조 (일부열실 등과 감액청구권)	설비 고장·누수로 사용이 어려운데도 차임 감액·해지를 금지하는 특약
민법 제634조 (임차인의 통지의무)	하자 통지 지연을 이유로 수선 책임을 임차인에게 전가하는 특약
민법 제640조 (차임연체와 해지)	1회 연체만으로 즉시 해지·강제퇴거하는 특약 (법정 기준은 2기 연체)
주택임대차보호법 제9조 (주택 임차권의 승계)	임차인 사망 시 계약 자동 종료·보증금 몰수 특약
공동주택관리법 제23조 (관리비 등의 납부 등)	관리비 명세 비공개, 임의 금액 부과 특약
공동주택관리법 제20조 (층간소음의 방지 등)	소음 민원 1회로 즉시 강제퇴거·위약금 부과 특약

왜 전체 법령을 통째로 넣지 않았는가

이 지식베이스는 조문 원문을 그대로 쌓아두는 구조가 아니라, 각 조문에 “이게 어떤 특약 상황에 적용되는지”를 사람이 직접 해설을 붙여 큐레이션한 것이다. 이 해설이 계약서 조항(구어체)과 법 조문(격식체) 사이의 문체 격차를 메워 검색 정확도를 높이는 핵심 요인이며, 원문을 기계적으로 대량 추가하면 관리 부담만 커지고 오히려 관련 없는 조문이 검색 결과에 섞여 정확도가 떨어질 위험이 있다. 그래서 주택 임대차보호법·민법 전체를 덤프하는 대신, **실제 학습 데이터에 등장하는 소재 중 법적 근거가 실재하는데 비어 있는 공백만 확인해서 타겟팅으로 추가**하는 방식을 택했다.

반대로 주차 관련 특약처럼 딱 맞는 특별법이 없는 소재는 억지로 조문을 끼워 맞추지 않고, 기존의 일반 조항(약관의 규제에 관한 법률 제6조 등 불공정 약관 일원원칙)으로 커버되도록 그대로 두었다. 근거가 약할 때 특정 조문을 억지로 인용하는 것보다 “근거 불충분”이라고 솔직히 답하는 편이 더 신뢰할 수 있는 결과라고 판단했기 때문이다.

7 RAG (3) 근거 필터링 임계값(min_score) 튜닝

임베딩 모델 교체로 baseline 유사도 자체가 높아지면서, 기존 임계값(0.25)은 무관한 조문까지 통과시키는 문제가 드러났다 (예: “반려동물 금지” 조항에 무관한 신탁법 조문이 0.45~0.48로 걸림). 실제 샘플 계약서로 반복 테스트하여 임계값을 조정했다.

테스트 케이스	매칭	유사도	판단
보증금 반환 거부(위험)	제3조의2 등 3건	0.68~0.70	명확히 유지되어야 함
무단 잠금장치 변경(주의)	형법 제319조(주거침입)	0.509	진짜 근거 — 반드시 살려야 함
반려동물 특수청소비(주의)	민법 제623조 등	0.38~0.41	해당 소재를 다루는 조문이 없어 생긴 약한 매칭 — 걸려야 함

0.509(진짜 근거)와 0.41 이하(노이즈) 사이에서 경계를 잡아 **min_score = 0.25 → 0.45**로 조정했다. 이 값은 “근거가 없으면 단정하지 말라”는 explainer의 프롬프트 원칙과도 맞물려, 애매한 조항에서는 근거 목록이 비게 되어 LLM이 “특정 법률로 직접 금지되진 않지만”처럼 더 정직하게 답하도록 유도한다.

8 통합 검증 — 실계약서 & 지식베이스 확장분

8-1. 실계약서 파이프라인 실행 검증

sample_contract.pdf (표준조항 4개 + 특약사항 5개, 총 9개 조항)를 전체 파이프라인에 직접 통과시켰다. **정상 6 / 주의 2 / 위험 1**로 분류되었으며, 위험·주의 조항 3건에 대해서만 RAG 검색과 Gemini 설명 생성이 실행됐다 (정상 조항은 API 호출 자체를 생략).

위험 임차인은 어떠한 사유로도 보증금 반환을 요구할 수 없다.

근거: 제3조의2(보증금의 회수) 0.6976 · 제3조의3(임차권등기명령) 0.6956 · 제3조의2 제7항(반환채무 승계) 0.6827

설명 요지: 임차권등기명령·보증금 반환채무 승계 규정을 근거로 사전 포기 약정은 무효라고 명확히 지적, 조항 삭제 강력 권고.

주의 월 차임이 1일이라도 지체되면 임대인이 사전 통지 없이 출입문을 잠글 수 있다.

근거: 형법 제319조(주거침입) 0.5092 · 제6조의2(목시적 갱신 해지) 0.4861

설명 요지: 임대인의 무단 출입/잠금장치 변경은 주거침입죄에 해당할 수 있음을 정확히 지적, 조항 삭제 요청 권고.

주의 반려동물을 기를 경우 퇴거 시 특수청소비 100만원을 무조건 지급한다.

근거: 없음 (임계값 0.45 미만으로 모두 필터링됨)

설명 요지: “특정 법률 조항으로 직접 금지되는 것은 아니지만, 실손해와 무관한 일률적 과다 청구는 분쟁 소지가 있다”고 솔직하게 답변 — 근거 없이 특정 조문을 억지로 인용하지 않음.

나머지 표준조항 4건과 특약사항 2건은 모두 정상으로 분류되어 별도 설명 생성 없이 통과됨.

8-2. 지식베이스 확장분(6절) 검증 — 8개 질의 전수 테스트

7건의 신규 조문이 의도한 상황에서 실제로 검색되는지 확인하기 위해, 기존 3개 질의에 신규 소재 5개 질의를 추가하여 총 8개 질의로 재검증했다.

질의	최상위 매칭	유사도	평가
임차인은 어떠한 사유로도 보증금 반환을 요구할 수 없다.	제3조의3(임차권등기명령)	0.7067	정확
임대인은 임차인의 전입신고를 금지한다.	제3조의6(확정일자부여)	0.5302	정확
임차인은 반려동물을 기를 수 없다.	(무관한 조문만 검색됨)	0.45~0.48	의도대로 — 해당 소재를 다루는 법이 없음
임차인이 관리비 명세를 요구해도 임대인은 항목을 공개하지 않는다.	공동주택관리법 제23조	0.7326	신규 조문, 정확
총간소음 민원이 한 번이라도 접수되면 임대인은 즉시 계약을 해지할 수 있다.	공동주택관리법 제20조	0.7103	신규 조문, 정확
보일러가 고장나도 수리 비용은 전액 임차인이 부담한다.	민법 제623조/626조	0.46/0.45	신규 조문, 정확하나 다소 약함(구체 단어 부재)
임차인이 사망하면 계약은 자동으로 종료되고 보증금은 반환하지 않는다.	주임법 제9조(임차권의 승계)	0.7003	신규 조문, 정확
차임을 1회만 연체해도 임대인은 즉시 계약을 해지하고 강제퇴거시킬 수 있다.	민법 제640조(차임연체와 해지)	0.7435	신규 조문, 정확

신규 추가 5개 질의 중 4개가 0.70~0.74의 높은 유사도로 정확한 조문을 최상위로 검색했고, 나머지 1개 (보일러 수리비)도 0.45~0.46으로 임계값을 통과하며 올바른 조문을 찾았다. 지식베이스 확장과 임계값 튜닝이 의도대로 작동함을 실측으로 확인했다.

9 왜 이 아키텍처가 단순 LLM API 호출보다 나은가

가장 단순한 대안은 계약서 전문을 그대로 프롬프트에 넣고 “위험 조항을 찾아 설명해줘”라고 LLM에 한 번에 요청하는 방식이다. 본 프로젝트는 (1) 세그멘테이션 (2) 파인튜닝 분류기 (3) RAG 검색 (4) LLM 설명 생성을 분리된 단계로 설계했다. 아래는 그 근거다.

구분	단순 LLM API 한 번 호출	본 파이프라인 (분류기+RAG+LLM)
법적 근거 정확성	모델이 내부 지식만으로 법 조문을 인용 → 조문 번호·내용을 그럴듯하게 지어내는 환각(hallucination) 위험	RAG가 실제 law_articles.json에서 검색한 조문만 프롬프트에 주입 → LLM은 주어진 근거 범위 안에서만 인용 가능
판단 일관성	같은 조항도 프롬프트/온도(temperature)에 따라 위험도 판단이 매번 달라질 수 있음	분류기는 고정된 가중치로 결정적·가깝게 판단 (동일 입력 → 동일 라벨), 762건 검증 데이터로 정확도 (0.980) 수치화 가능
비용·속도	계약서의 모든 조항(9개)마다 매번 LLM 호출	분류는 로컬 소형 모델(무료·고속)이 전담하고, 위험·주의로 판정된 조항(본 테스트에서 3/9, 33%)에 대해서만 LLM API 호출 → 호출량 최소화
검증 가능성	출력 결과만 있고 왜 그렇게 판단했는지 근거가 불투명 (블랙박스)	라벨 확신도(confidence), 근거 조문, 유사도 점수가 모두 함께 출력되어 사람이 결과를 직접 검증할 수 있음
법 개정 대응	법이 바뀌면 프롬프트를 다시 손보거나 모델의 내부 지식 업데이트를 기다려야 함	law_articles.json만 갱신하면 즉시 반영, 분류 모델 재학습 불필요
개인정보 노출	계약서 전문(임대인·임차인 정보 포함 가능)을 매번 외부 API로 전송	정상 조항은 API로 전송조차 되지 않고, 위험·주의 조항만 마스킹 후 전송되어 노출 범위 최소화
도메인 특화	범용 모델은 한국 주택임대차법의 세부 뉘앙스(강행규정 vs 임의규정 등)를 놓칠 수 있음	분류기를 한국 임대차 특약사항 데이터로 직접 파인튜닝하여 도메인에 맞게 최적화, 성능을 762건 데이터로 실측

핵심 요약: LLM은 “그럴듯한 문장을 생성하는 데” 강하지만 “이 조항이 왜 위험한지에 대한 정확한 법적 근거를 아는 데”는 근본적으로 취약하다(파라미터에 저장된 지식은 오래되거나 부정확할 수 있고, 확인되지 않은 사실도 확신 있게 말할 수 있다). 본 아키텍처는 “판단(분류)”과 “근거 조회(RAG)”를 LLM 바깥에서 검증 가능한 형태로 처리하고, LLM은 마지막 단계인 “근거를 사람이 이해하기 쉬운 문장으로 풀어 설명하는 역할”에만 국한시킨다. 실제로 8-1절의 “반려동물 청소비” 사례에서, 근거가 없을 때 LLM이 억지로 조문을 갖다 붙이지 않고 “직접적으로 금지되지 않지만”이라고 정직하게 답한 것이 이 설계의 효과를 보여준다.

10 한계 및 향후 과제

구분	내용
RAG 커버리지	주차 관련 특약처럼 특정 법 조문이 존재하지 않는 소재는 여전히 근거 없이 “주의” 판단에만 의존 — 약관의 규제에 관한 법률 등 일반 조항과의 매칭 정교화 여지
임계값(0.45) 검증 규모	실계약서 1건(9개 조항) + 지식베이스 확장분 8개 질의라는 소규모 사례로 튜닝된 값이라, 더 많은 계약서 샘플로 검증이 누적되어야 함
LLM 설명 생성 자체의 한계	RAG로 근거를 제한해도 Gemini의 문장 생성 과정에서 미세한 과장·왜곡 가능성은 완전히 배제되지 않음 (사람의 최종 확인 필요)
입력 범위	텍스트 추출 가능한 전자계약 PDF 전제, 스캔본/이미지 PDF는 별도 OCR 필요
법적 효력	참고용 도구이며 법적 효력을 갖는 자문을 대체하지 않음
확장 가능성	설명 생성 단계를 자체 LoRA 파인튜닝 모델로 대체해 외부 API 의존도 축소 검토 가능

11 결론

본 파트는 부동산 임대차 계약서의 특약사항을 검토하는 “법률 상담사/1차 검토자” 역할을, 세그멘테이션 → 파인튜닝 분류기 → RAG 검색 → LLM 설명 생성이라는 4단계 파이프라인으로 대체했다. 분류기는 데이터 누수·길이 편향·라벨 불균형을 순차적으로 진단하고 해결하며 accuracy·macro F1 0.980까지 끌어올렸고, RAG는 임베딩 모델 교체(KoE5)와 지식베이스 타겟 확장(38→45건), 임계값 재튜닝(0.25→0.45)을 통해 실제 계약서에서 검증 가능한 수준의 근거 검색 품질을 확보했다. 무엇보다 각 단계의 성능과 한계를 수치와 실제 테스트 사례로 투명하게 검증했다는 점이, 계약서를 통째로 LLM에 맡기는 단순한 접근과 본 시스템을 구분 짓는 가장 중요한 차이다.